COMPETITION PROJECT / FINAL RESULTS

무릎 MRI 이상 소견 탐지 연구

판독문 기반 약지도 학습과 MRI 영상 선택, 다중 모델 앙상블을 통한 12개 이상 소견 예측

0.958	0.941	949
BEST PUBLIC AUC	FINAL PRIVATE AUC	FINAL RANK
공개 평가 최고	최종 제출 점수	공식 최종 순위

01 무엇을 해결했는가

이 프로젝트는 한 번의 무릎 자기공명영상(MRI) 검사에서 12가지 이상 소견이 존재할 가능성을 예측하는 머신러닝 모델을 연구했다. 예측 대상에는 인대 손상, 반월상연골 손상, 골관절염, 관절액 증가, 활막염, 낭종, 골좌상 및 골절이 포함된다.

한 환자의 MRI 검사에는 촬영 방향과 영상 특성이 다른 여러 시리즈(Series)가 포함되며, 이상 소견이 전체 이미지 중 일부에만 나타날 수 있다. 따라서 모든 영상을 읽는 효율성과 병변에 중요한 영상을 찾아내는 능력이 핵심 과제였다.

02 프로젝트가 수행한 세 가지 핵심 작업

1. **보고서에서 학습용 정답 구성**
   영상마다 제공된 판독문에서 질환 단서를 추출하고, 불확실한 진술에는 별도 가중치와 라벨 정책을 적용했다.

2. **MRI에서 병변 관련 영상 선택**
   영상 특징 추출기와 주의집중 모델을 이용해 필요한 영상 구간을 골라 재판독하는 구조를 실험했다.

3. **서로 다른 모델의 예측 결합**
   자체 학습 모델과 공개 고성능 모델을 검토하고, 12개 소견별로 다른 결합 가중치를 적용했다.

RESEARCH DESIGN / FROM REPORT TO MRI

데이터 · 평가 기준 · 접근 방법

03 데이터는 어떻게 구성되었는가

4,407	4,349	58
Training studies	Weakly labeled	Curated gold
영상 검사 건수	판독문 기반 라벨 구성	제한된 기준 라벨

MRI는 DICOM 의료영상 파일로 제공된다. Study는 환자의 한 검사 단위, Series는 검사 안의 하나의 촬영 시퀀스, Slice는 시퀀스 안의 개별 2차원 단면 영상이다. 최종 예측은 Slice가 아니라 Study 단위로 수행했다.

> 라벨의 어려움: 58건에만 정리된 12개 소견 라벨이 제공되고, 나머지는 자유 서술형 판독문이 중심이다. 직접 명시된 양성 · 음성, 미언급, 표현의 모호성을 구분하는 라벨 정책이 모델 학습 품질에 영향을 준다.

04 영상에서 최종 확률까지의 처리 흐름

01 MRI 정규화

영상 순서 정렬, 픽셀 값 정규화, 촬영 방향 · 유효 Slice 처리

02 영상 특징 추출

DINOv2 · CoAtNet 등 신경망으로 영상 표현 추출

03 병변 관련 구간 선택

Multiple - instance learning(MIL)과 소견별 Attention으로 중요 영상 강조

04 결합 및 예측

서로 다른 reader의 12개 출력 확률을 소견별로 앙상블

> 평가 지표: 12개 소견의 ROC - AUC를 각각 계산한 뒤 단순 평균(Macro - AUC)한다. Public LB는 대회 중 공개 테스트 일부, Private LB는 대회 종료 후 최종 평가 집합이다.

OWN EXPERIMENTS / KEY FINDINGS

핵심 연구: 영상 선택과 모델 다양성

05 자체 모델 구조는 어떻게 발전했는가

첫 계열에서는 전체 MRI를 곧바로 예측하는 모델과 유용한 영상만 다시 판독하는 모델을 조합했다. 이후 DINOv2(사전학습 이미지 특징 추출기)와 MIL(여러 영상 중 중요한 구간에 집중하는 학습 방식)을 적용했고, 선택된 영상의 추가 미세조정도 실험했다.

Public AUC	기술적 변화와 검증 결과
0.918	병변 후보 영상을 고른 재판독 + 전체 MRI 예측 결합
0.923	전체 영상 특징에 질환별 Window Attention 도입
0.926	상위 18개 영상 집중 재학습과 직접 예측 결합
0.928	DINO 기반 영상 선택 모델의 추가 개선
0.934	서로 다른 구조의 DINO · CoAtNet 예측을 결합

06 독립 모델을 추가한 이유

DINO 계열 외에도 96개 MRI 단면을 밀도 있게 읽는 CoAtNet 모델을 자체 학습했다. CoAtNet의 정밀 라벨 미세조정 단독 점수는 0.929, 판독문 기반 혼합 라벨 학습 후 단독 점수는 0.935였다.

반면 촬영 위치 정보를 활용해 국소 부위를 보는 자체 ConvNeXt 모델의 단독 점수는 0.854였다. 구조가 새롭다는 이유만으로 최종 앙상블에 넣지 않고, 실제 검증 성능을 기준으로 제외했다.

> 실험 번호는 추적 목적이다. 이 페이지의 점수는 모두 대회 Public Macro - AUC이며, 서로 다른 학습 계열 · 제출을 비교한 관측값이다.

ENSEMBLE / INFERENCE ENGINEERING

성능 개선: 앙상블과 안정적인 추론

07 공개 고성능 모델 활용과 자체 개선을 구분

후반에는 공개된 고성능 예측 모델 · 가중치를 활용했다. 공개 CoAtNet 384px 판독기와 ConvNeXt 기반 모델(S6F0)의 결과를 소견별 순위값으로 변환한 뒤 결합하여 Public 0.955를 확인했다. 최종 MAIN 제출의 Public 0.958은 이 강한 공개 계열을 활용한 최종 예측 파이프라인에서 기록한 값이다.

> 성과 귀속: DINO/MIL, CoAtNet Wide96, Weak2 등 자체 학습 · 분석 과정과 외부 공개 checkpoint 기반의 최종 앙상블은 구분해야 한다. Public 0.958 전체를 독자 모델 단독 학습 성능으로 해석해서는 안 된다.

08 약한 소견을 별도 예측기로 보강한 실험

일부 소견(활막염 · 외측 골관절염)의 예측을 보강하기 위해, 의료영상 사전학습 ResNet50 기반 보조 모델을 1,075개 Study / 6,014개 Series로 학습했다. 양 · 음성 불균형을 고려해 샘플링과 라벨 스무딩을 적용했다.

내부 58건 진단 평가 (Gold58)

활막염 ROC-AUC 0.756 | 외측 골관절염 0.803

기존 공개 모델에 추가한 제출의 Public 점수는 0.955로 동일했다.

09 숨겨진 평가 데이터에서도 제출이 멈추지 않도록

- 영상 정렬: DICOM 촬영 위치를 우선 사용하고 불완전한 메타데이터를 보수적으로 처리.
- 오류 복구: Slice → Series → 모델 분기 순서로 가능한 실제 영상 예측을 유지.
- 실패 은폐 금지: 예측 실패를 고정 0.5 값으로 채우지 않고, 대체 예측 불가 시 중단.

FINAL EVALUATION / PROVENANCE

최종 대회 결과와 연구의 한계

10 공개 순위와 최종 점수는 달랐다

최종 제출 비교	Public AUC	Private AUC
최종 MAIN 제출	0.958	0.941
이전 70:30 비율 변경 제출	미확인	0.942

949
공식 최종 순위

~240
대회 중 공개 최고 순위

최종 MAIN은 Public 0.958이었지만 Private은 0.941이었다. 이전의 단순 70:30 혼합비 변경 제출이 Private 0.942로 조금 더 높았다. 이는 공개 점수에 맞춘 세밀한 튜닝이 최종 보지 못한 데이터에서 항상 유리하지 않음을 보여준다.

11 연구로 얻은 실무적 시사점

- 표현과 선택을 분리하면 대량 영상의 계산 비용을 줄이면서 주요 병변에 집중할 수 있다.
- 판독문 기반 약지도 라벨의 불확실성과 소규모 검증셋 과적합을 함께 관리해야 한다.
- 독립 전문가 모델의 상호 보완성이 중요하지만, 보조 모델 추가 자체가 이득을 보장하지는 않는다.
- GPU 활용률 · 저장장치 I/O · 재현성 · 오류 복구가 최종 제출 품질을 좌우한다.

12 범위와 근거 자료

이 연구는 Kaggle 경진대회용 시스템이다. 임상 외부 검증이나 의료기기 인허가를 수행한 것은 아니다. 수치는 대회 공식 점수와 자체 개발 검증을 구분해 기재했다.

공식 대회	kaggle.com/competitions/rsna-knee-abnormality-detection
실험 기록	github.com/dudghks5893/RSNA-Knee-Abnormality-Detection